

Slovenská technická univerzita

Fakulta informatiky a informačných technológií

Ilkovičova 3, 842 16 Bratislava 4

Dopredná neurónová sieť

Martin Čertek

Predmet: Neurónové siete

Vedúci projektu: doc. Ing. Michal Čerňanský, PhD.

Ak. rok: 2013/2014

Zadanie

V ľubovolnom programovacom jazyku implementujte jednoduchý simulátor doprednej neurónovej siete (vstupy a parametre simulácie sa musia dať meniť bez nutnosti kompilovania). Natrénujte ju algoritmom spätného šírenia chyby na vstupných množinách:

- XOR - 2 vstupné neuróny , 1 výstupný neuron, 4 vstupné vzory
- Binárna parita – 8 vstupných neurónov, 1 výstupný neuron, 256 vstupných vzorov
- vlastnej množine dát

Sieť trénujte na celej vstupnej množine a počas trénovania zobrazujte percentuálnu úspešnosť klasifikácie (kolko percent zo vstupov je uz správne klasifikovaných).

Návrh siete

Riešenie vychádza z požiadaviek a je navrhnuté ako dopredná neurónová sieť zo spätnou propagáciou chyby.

Definícia výpočtu váhy

```
edge.weight = (learningRate * self.lastOutput * (1 - self.lastOutput)
* self.error * self.lastInput[i]) + (momentum * edge.lastWeight)
```

, kde lastOutput sa rovná $f(x)$

Implementácia

Riešenie zadanie je implementované v jazyku python. Implementácia je rozdelená do 3 samostatných súborov. Prvý obsahuje vytvorenie a prácu zo sieťou, druhý slúži ako pomocný pre prácu zo súbormi (načítanie), tretí ako hlavný súbor, kde prebieha volanie siete a operácie nad ňou a dátami. Riešenie je v podobe konzolovej aplikácie s jednoduchým textovým výstupom, bez grafických prvkov.

Riešenie je založené na objektovom prístupe. Vychádza z viacerých definovaných objektov:

Network (neurónová sieť)

Návrh vychádza z konceptu objektu – network, kt. uchováva list vstupných Nodov (vstupných neurónov inputNode) a hiddenNodes/outputNode, ktoré sú objektmi typu Node.

Node (neuron)

```
class Node:

    def __init__(self):
        self.lastOutput = None
        self.lastInput = None
        self.error = None
        self.outgoingEdges = []
        self.incomingEdges = []
        self.addBias()
```

Edge (hrana)

```
class Edge:
    def __init__(self, source, target, index_i, index_j):
        self.weight = random.uniform(-0.5, 0.5)
        self.source = source
        self.target = target
        self.lastWeight = 0
        self.index_i = index_i
        self.index_j = index_j

        # pripojenie hran k ich neuronom |
        source.outgoingEdges.append(self)
        target.incomingEdges.append(self)
```

Výpočet váhy:

```
edge.weight += (learningRate * self.lastOutput * (1 - self.lastOutput) *
                self.error * self.lastInput[i]) + (momentum * edge.lastWeight)
```

Dáta

XOR

```
xorData = [
    ((0, 0), 0),
    ((0, 1), 1),
    ((1, 0), 1),
    ((1, 1), 0),
]
```

Parita

Dátovú množinu tvoria všetky možné kombinácie (1/0) pri dĺžke 8 bit = 256 možností. Po každej možnosti nasleduje informácia (1/0), o nepárnosti/párnosti počtu „1“ v reťazci.

Dáta su v implementačnom jazyku preprezentované ako množina *touple* :

```
[ ((0, 0, 0, 0, 0, 0, 0, 0, 0), 0),  
  ((0, 0, 0, 0, 0, 0, 0, 0, 1), 1),  
  ((0, 0, 0, 0, 0, 0, 1, 0), 1),  
  ...  
  ((1, 1, 1, 1, 1, 1, 1, 1, 1), 0)  
]
```

Telco

Doplňujúcou množinou dát na overenie fungovania neurónovej siete je množina dát z telekomunikačnej oblasti. Táto množina zachytáva:

- demografické faktory
 - pohlavie, miesto bydliska – v rôznych rozsahoch, získané vzdelanie (SŠ/VŠ)
- časový interval, koľko rokov je osoba zákazníkom spoločnosti
- rozhodnutie o zrušení zákaznického vzťahu

Dáta sú tvorené 12 voliteľnými atribútmi a 1 ktorý predstavuje výsledok. Počet záznamov je 3000.

Dáta su v implementačnom jazyku uložené v množine *touple*

```
[ ((1, 1, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0), 1),  
  ((0, 1, 1, 0, 0, 0, 0, 0, 0, 0, 1, 1), 1),  
  ((0, 1, 0, 0, 0, 0, 1, 0, 0, 1, 0, 1), 1),  
  ...  
  ((1, 0, 1, 0, 0, 0, 0, 0, 1, 0, 0, 1), 1) ]
```

Z povahy dát možno očakávať niektoré závery:

na základe skúseností a komunikácie s oddelením predaja, najčastejšie odchádzajúci sú klienti, ktorí sú tesne po konci prvej viazanosti, teda v dĺžke kontraktu (1-3 roky), sú mužského pohlavia, vysokoškolsky vzdelaní a žijú vo väčších mestách a sú vo vekovom rozpätí 18-25 rokov.

Podľa informácií zo spoločnosti sú takýto klienti najnáchylnejší na odchod ku konkurencii, no nepredstavujú extrémne odlišen sa chovajúcu množinu. Rozdiel v migrovaní u nich a u množiny rovnakej, resp. dolišujúcej sa iba ženským pohlavím je niekoľko percentný, nie niekoľko násobný.

Na základe týchto postulátov budeme nazerať na dáta, ktoré budú v časti Testovanie podrobnejšie overené.

Použitie siete

Riešenie je implementované ako konzolová aplikácia v jazyku python, spustenie siete a natrénovanie je realizované zadaním príkazu, s konfigurovateľnou množinou atribútou špecifikujúcich jednotlivé parametre pre beh danej siete.

```
python neuralnetwork-tests.py parity 0.5 0 100000 8 8
```

Parametre:

xor/parity/telco:

definuje s akými dátami bude sieť pracovať

learning rate

učiaci faktor (hodnoty 0-1)

momentum

aplikované hodnoty (hodnoty 0-1)

maximálny počet iterácií pre beh siete

- celé číslo (pre rôzne vstupy je potrebné nastaviť iné parametre – príliš veľké číslo znamená presnejšie natrénovanie, no násobne rásť zložitosť výpočtu a teda aj času)

počet vstupných neurónov

zodpovedá počtu vstupných informácií pre každý vstupný vektor

počet neurónov v skrytej vrstve

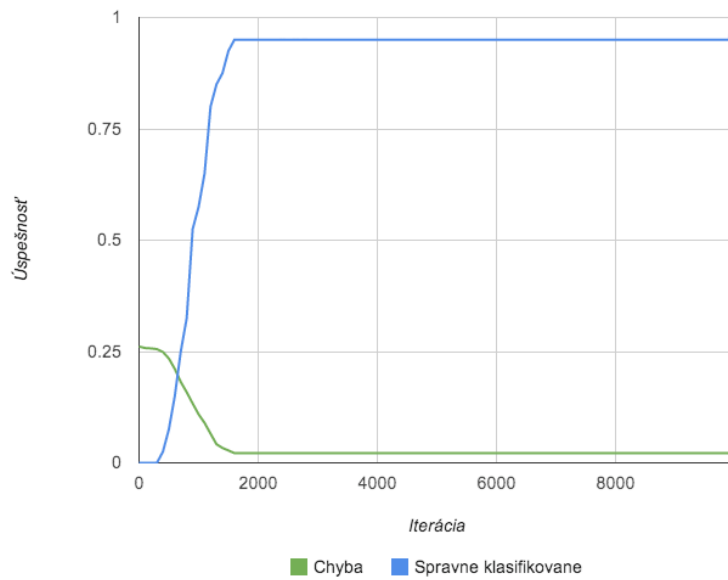
početnosť neurónov – parameter meniaci sa s počtom vstupných neurónov
v rozmedzí: počet vstupných neurónov – n (prie behu siete bolo skúšaných max 2 počet vstupných neurónov)

Testovanie

XOR

parametre experimentu:

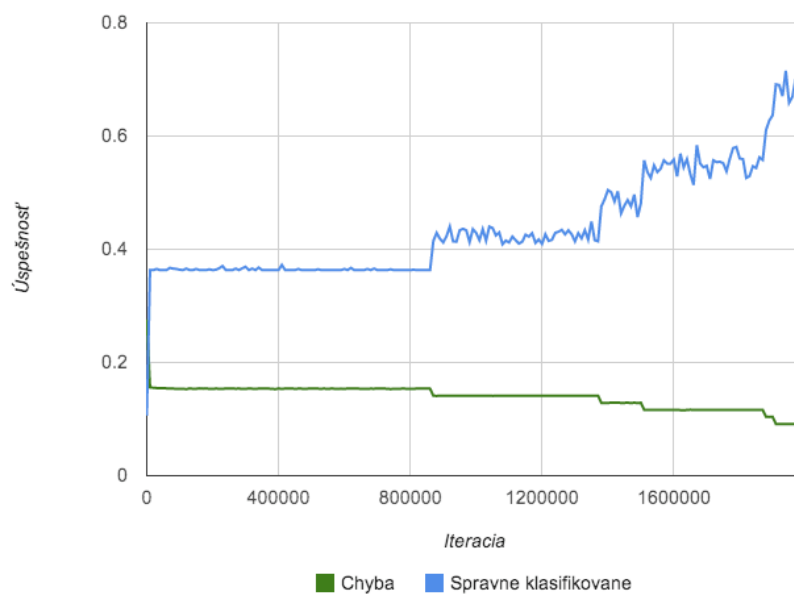
learning rate 0,3 ; momentum 0; 2 neurony v skrytej vrstve,



Parita

Experiment s parametrami:

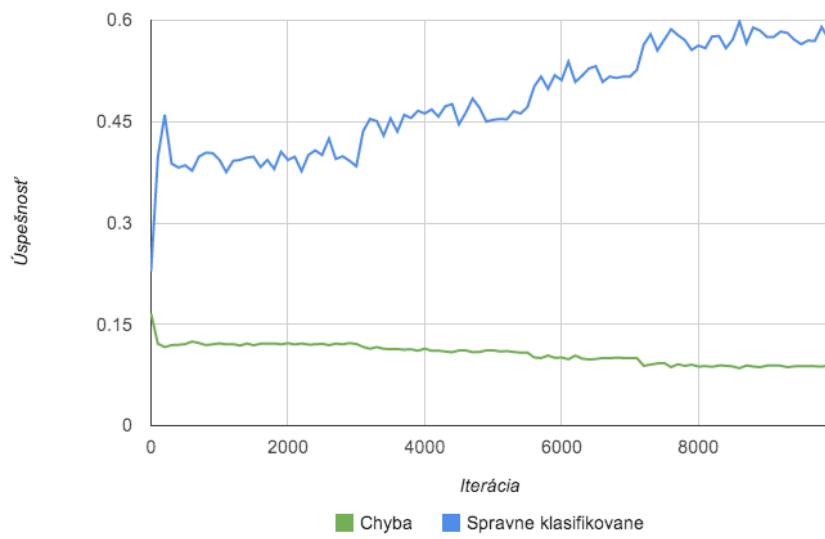
learning rate 0,3; momentum 0; 8 neurónov v skrytej vrstve



Telco dáta

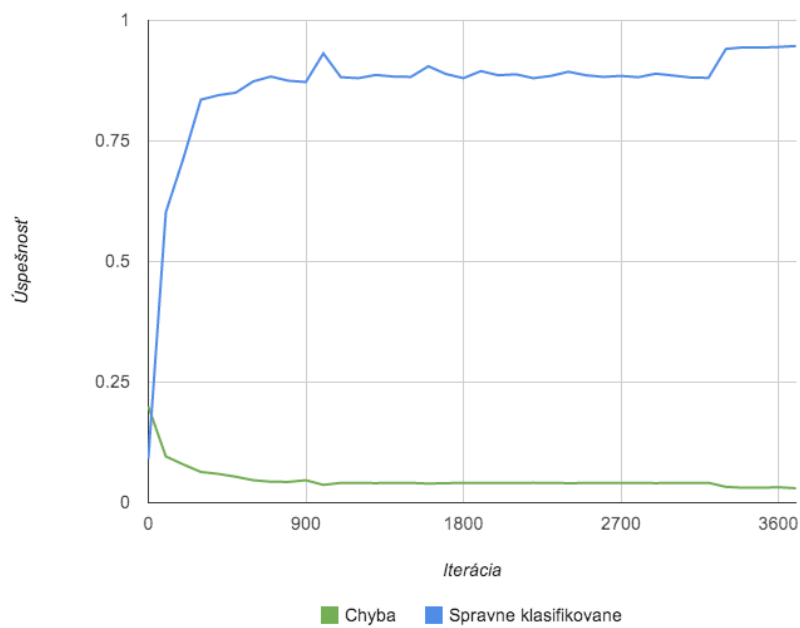
Experiment s parametrami:

learning rate 0,6; momentum 0,8 ; 12 neurónov v skrytej vrstve



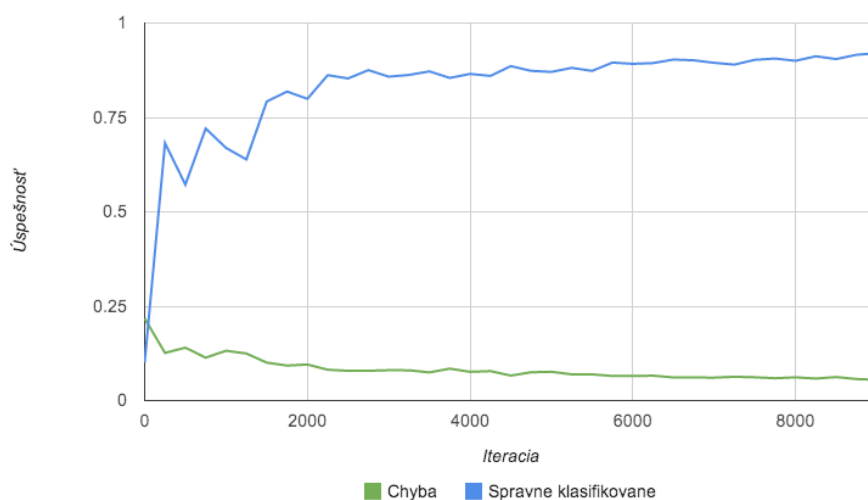
Experiment s parametrami:

learning rate 0,2; momentum 0,8 ; 12 neurónov v skrytej vrstve



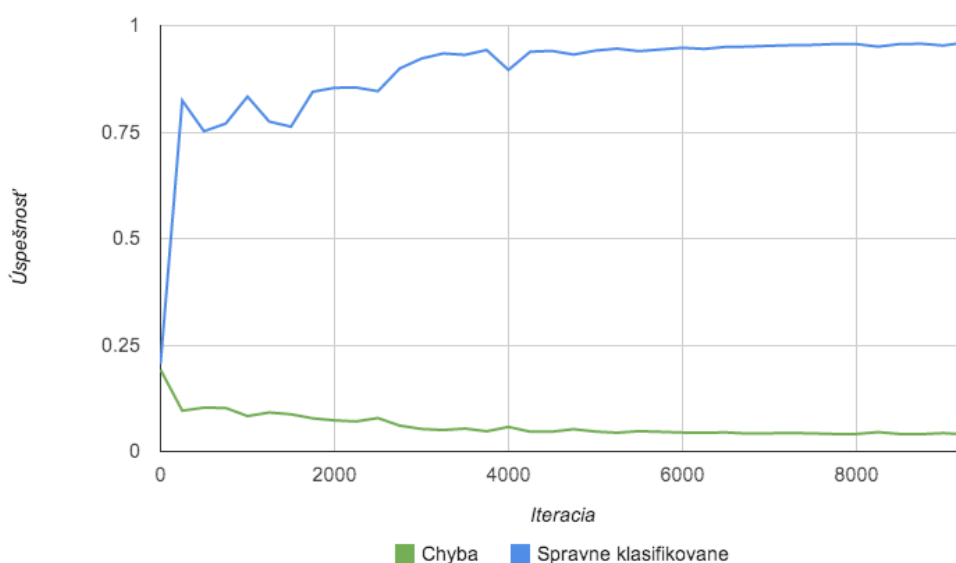
Experiment s parametrami:

learning rate 0,3; momentum 0,8; 14 neurónov v skrytej vrstve



Experiment s parametrami:

learning rate 0,3; momentum 0,8; 16 neurónov v skrytej vrstve



Zhodnotenie

Implementácia neurónovej siete predstavovala netriviálny problém. Z pohľadu implementácie bolo najnáročnejšou fázou odladenie samotnej implementácie a zabezpečenie jej funkčnosti a správnosti výsledkov.

Na tieto účely slúžilo najmä implementovanie a otestovanie siete pre množinu XOR, kde sa dala manuálne overiť správnosť, rovnako bola sieť testovaná aj pre

množinu dát – paritu, ktorá svojo komplexnosťou preverila funkčnosť a výpočtovú zložitosť – čas behu siete.

Po tejto časti práce prišlo na rad otestovanie vlastných dát. úloha, kt. bola postavená a ktorá mala z dát overiť správnosť hypotézy je podrobnejšie zdokumentovaná v časti testovanie.

Hypotéza, ktorá predpokladala na základe skúseností, že klienti, ktorí majú najväčšiu tendenciu končiť zmluvy (a prechádzať ku konkurencii) sú muži, vo veku 18-25 rokov, bývajúci v meste s dĺžkou kontraktu 2-5 rokov sa ukázala ako opodstatnená, čo dokumentuje nárast ukončenia zmlúv oproti iným skupinám. Úspešnosť správnej identifikácie „odchodu“ na základe 12 atribútov sa pohybovala v rozmedzí 90-95 % čo možno hodnotiť ako spoľahlivé zatriedovanie.

Nárast sa pohybuje medzi 3-5 percentami oproti najbližšej uvažovanej skupine:

